

MAE 5776

ANÁLISE MULTIVARIADA

Júlia M Pavan Soler
pavan@ime.usp.br

1º Semestre/2022

MAE5776

😊 Já vimos

Matriz de Dados: $Y_{n \times p} = (Y_{ij}) \in \mathbb{R}^{n \times p}$; $Y_{i \times 1} \stackrel{\text{iid}}{\sim} (\mu_{p \times 1}; \Sigma_{p \times p}), i = 1, \dots, n$

Estatísticas descritivas multivariadas: $\bar{Y}_{p \times 1}, S_{p \times p}, R_{p \times p}, S_{p \times p}^{-1}$ $D_{n \times n} = (d_{ij}^2), d_{Pij}^2, d_{Mij}^2$

Regiões (elipsóides) de Concentração de Observações:

$$R(Y_i) = \left(Y_i \in \mathbb{R}^p; d_M^2(Y_i; \mu) = (Y_i - \bar{Y})' S_u^{-1} (Y_i - \bar{Y}) \leq c^2; c^2 = \chi_p^2(\alpha) \right)$$

Matriz de Dados Aleatórios: $Y_{n \times p} \in \mathbb{R}^{n \times p}$; $Y_i \stackrel{\text{iid}}{\sim} N_p(\mu_{p \times 1}; \Sigma_{p \times p}), i = 1, \dots, n$

- Caso de **Uma única População**: $H_0: \mu = \mu_0$ Teste T^2 de Hotelling

$$T^2 = n(\bar{Y} - \mu)' S_u^{-1} (\bar{Y} - \mu) \leq c^2; \quad c^2 = \frac{(n-1)p}{(n-p)} F_{p, (n-p)}(\alpha)$$

- Caso de **Duas Populações**: $H_0: \mu_1 = \mu_2 \Leftrightarrow H_0: \mu_D = 0$ Teste T^2 de Hotelling

$$T^2 = n(\bar{D} - \mu_D)' S_D^{-1} (\bar{D} - \mu_D) \leq c^2; \quad c^2 = \frac{(n-1)p}{(n-p)} F_{p, (n-p)}(\alpha) \quad \text{Dados dependentes}$$

$$T^2 = (\bar{D} - \mu_D)' \left(S_c \left(\frac{1}{n_1} + \frac{1}{n_2} \right) \right)^{-1} (\bar{D} - \mu_D) \leq c^2; \quad c^2 = \frac{(n_1 + n_2 - 2)p}{(n_1 + n_2 - p - 1)} F_{(p; n_1 + n_2 - p - 1)}(\alpha)$$

Dados independentes e Homocedásticos, $\Sigma_1 = \Sigma_2$

Teste da Igualdade de Matrizes de Covariância

Comparação de Vetores de Médias - Amostras Independentes e Homocedasticidade

$$Y_{1n_1 \times p}; Y_{1i} \stackrel{iid}{\sim} N_p(\mu_1; \Sigma_1) \quad Y_{2n_2 \times p}; Y_{2i} \stackrel{iid}{\sim} N_p(\mu_2; \Sigma_2) \quad \left\{ \begin{array}{l} S_{ug} = \frac{1}{n_g - 1} \sum_{i=1}^{n_g} (Y_{gi} - \bar{Y}_g)(Y_{gi} - \bar{Y}_g)'; g = 1, 2 \\ S_c = \frac{(n_1 - 1)S_{u1} + (n_2 - 1)S_{u2}}{n_1 + n_2 - 2}; \end{array} \right.$$

$$\Rightarrow H_0 : \mu_1 - \mu_2 = 0 \quad ; \Sigma_1 = \Sigma_2 = \Sigma$$

É uma Hipótese condicional.
Logo a homocedasticidade
deve ser verificada.

■ **Teste M de Box:** $\Rightarrow H_0 : \Sigma_g = \Sigma; \mu_g \in \mathbb{R}^p$

É a estatística da Razão de Verossimilhanças (sob N_p)
Para $p=1$ o teste de Box equivale ao teste de Bartlett.

$$M = (1 - c) \left\{ \left[\sum_{g=1}^G (n_g - 1) \right] \ln |S_c| - \sum_{g=1}^G \left[(n_g - 1) \ln |S_{ug}| \right] \right\} \sim \chi^2_{\frac{1}{2}p(p+1)(G-1)}$$

$$c = \left[\sum_{g=1}^G \frac{1}{(n_g - 1)} \right] \left[\frac{2p^2 + 3p - 1}{6(p+1)(G-1)} \right]$$

Critério “prático” de heterocedasticidade sugerido em Johnson and Wichern 1992:

$$\sigma_{gij} = 4\sigma_{g'ij}$$

Inferência sobre Vetores de Médias de Duas Populações

Caso Multivariado - Amostras Independentes – Heterocedasticidade

Teoria Assintótica

$$Y_{1n_1 \times p}; Y_{1i} \stackrel{iid}{\sim} N_p(\mu_1; \Sigma_1); \quad Y_{2n_2 \times p}; Y_{2i} \stackrel{iid}{\sim} N_p(\mu_2; \Sigma_2)$$

$$\bar{D}_{p \times 1} = \bar{Y}_1 - \bar{Y}_2 \sim N_p\left(\mu_D = \delta = \mu_1 - \mu_2; \Sigma_{\bar{D}} = \left(\frac{\Sigma_1}{n_1} + \frac{\Sigma_2}{n_2}\right)\right)$$

$$\Rightarrow H_0 : \mu_D = \delta_0; \quad \Sigma_g \in \mathcal{R}^{p \times p}, g = 1, 2$$

Hipótese condicional, sob heterocedasticidade (resultados assintóticos).

$$T^2 = (\bar{D} - \delta_0)' \left(\frac{S_1}{n_1} + \frac{S_2}{n_2} \right)^{-1} (\bar{D} - \delta_0) \stackrel[n_2 - p \rightarrow \infty]{n_1 - p \rightarrow \infty} \sim \chi_p^2$$



Pesquisa:

- Método de Welch para aproximações dos graus de liberdade da estatística de teste sob heterocedasticidade (Kaiser e Bowden, 1983)
- Algoritmo de Behrens-Fisher: Testar a igualdade dos vetores de médias “SEM” suposições sobre as matrizes de covariâncias

Inferência: Vetores de Médias de Duas Populações

Correções para Múltiplos Testes

$$\underbrace{Y_{1i} \stackrel{iid}{\sim} N_p(\mu_1; \Sigma_1)} \quad \underbrace{Y_{2i} \stackrel{iid}{\sim} N_p(\mu_2; \Sigma_2)}$$

Dados Dependentes*1: $n_1 = n_2 \Rightarrow D_i, \quad i = 1, \dots, n \quad \bar{D} \quad S_{\bar{D}} = S_D \frac{1}{n}$

Dados Independentes*2: $n_1 \Rightarrow \bar{Y}_1 \quad S_1 \quad n_2 \Rightarrow \bar{Y}_2 \quad S_2 \quad \bar{D} \quad S_{\bar{D}} = S_c \left(\frac{1}{n_1} + \frac{1}{n_2} \right)$

Intervalos de Confiança Simultâneos (para combinações lineares das p variáveis)

$$\Rightarrow ICS(\mu_{Dj}) a(1-\alpha) \times 100\% = \left(\bar{D}_j \mp \sqrt{\frac{\nu_1}{\nu_2} F_{\nu_1, \nu_2}(\alpha)} \sqrt{S_{\bar{D}jj}} \right)$$

*1: $\nu_1 = (n-1)p, \quad \nu_2 = (n-p)$
 *2: $\nu_1 = (n_1 + n_2 - 2)p, \quad \nu_2 = (n_1 + n_2 - p - 1)$

Intervalos de Confiança de Bonferroni (correção para múltiplos testes)

$$\Rightarrow ICB(\mu_{Dj}) a(1-\alpha) \times 100\% = (\bar{Y}_{1j} - \bar{Y}_{2j}) \pm t_{\nu}(\alpha/2p) \sqrt{S_{\bar{D}jj}}$$

*1: $\nu = (n-1)$
 *2: $\nu = (n_1 + n_2 - 2)$

Inferência sobre Vetores de Médias

Comparações Múltiplas e o Problema de Múltiplos Testes

$$\begin{aligned}
 Y_{1i} &\stackrel{iid}{\sim} N_p(\mu_1; \Sigma_1) \rightarrow n_1 \\
 Y_{2i} &\stackrel{iid}{\sim} N_p(\mu_2; \Sigma_2) \rightarrow n_2
 \end{aligned}
 \Rightarrow \begin{cases} H_0 : \mu_{1 \times p} = \mu_{2 \times p} \\ H_1 : \mu_{1 \times p} \neq \mu_{2 \times p} \end{cases}$$

Estatística T^2 : **Teste simultâneo** para as p variáveis a um nível de significância α . Ao rejeitar H_0 , há diferença entre os grupos para pelo menos uma variável ou alguma combinação linear delas!

Exemplo: Dados Iris
Comparar Virginica x Setosa
Estatística T^2 é **significante**
Neste caso $p=4$ Variáveis.
Para qual variável os grupos são diferentes?

$$\left\{ \begin{array}{ll} H_{01} : \mu_{1g=1} = \mu_{1g=2} & \Rightarrow \alpha_1 \\ H_{02} : \mu_{2g=1} = \mu_{2g=2} & \Rightarrow \alpha_2 \\ H_{03} : \mu_{3g=1} = \mu_{3g=2} & \Rightarrow \alpha_3 \\ H_{04} : \mu_{4g=1} = \mu_{4g=2} & \Rightarrow \alpha_4 \end{array} \right. \quad \begin{array}{l} \alpha_c? \\ \text{Valor-p ajustado?} \end{array}$$

Para testar as 4 hipóteses, qual é o nível de significância global?

Em Estudos envolvendo Comparações Múltiplas é necessário obter um nível de significância corrigido para a Família de Comparações de interesse.

Inferência sobre Vetores de Médias

Comparações Múltiplas e o Problema de Múltiplos Testes

$$H_{0k} \times H_{1k} \quad k = 1, \dots, K$$

$$P(\text{pelo menos uma Rej } H_0) = 1 - P(\text{nenhuma Rej } H_0)$$

$$= 1 - \prod_{l=1}^K P(p_l > \alpha) = 1 - (1 - \alpha)^K \xrightarrow{K \rightarrow \infty} 1$$

```
> B<-10000
> K<-500
> set.seed(1299)
minpval <- replicate(B,
min(runif(K, 0, 1))<0.01)
table(minpval)
table(minpval)[2]/B
```

```
> table(minpval)
minpval
FALSE  TRUE
   78   9922
> table(minpval)[2]/B
   TRUE
0.9922
```

Quando o número de testes (K), realizados simultaneamente, cresce, é alta a probabilidade de obter resultados significantes ao acaso (Falsos Positivos)

Critérios de Correção do nível de significância individual para garantir um nível de significância coletivo igual a α (em geral, 5%):
Bonferroni, Holm, FDR

Inferência sobre Vetores de Médias

Comparações Múltiplas e o Problema de Múltiplos Testes

Rejeitar H_{0j} se:	Método
$p_{(k)} < \alpha / K$	Correção de <u>Bonferroni</u> para múltiplos testes
$p_{(j)} < \alpha / (K - j + 1)$	Correção de <u>Holm</u> (Controle “forte” da taxa de erro para os múltiplos testes)
$p_{(j)} < j\alpha / K$	Correção FDR (Taxa de Falsa Descoberta): <u>Benjamini-Hochberg</u> Controle menos conservador da taxa de erro para os múltiplos testes)

K : número total de testes α : nível de significância global fixado

$p_{(j)}$: nível descritivo (p-valor) ordenado, $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(K)}$

Oficina no R

Comparação de Vetores de Médias de Duas Populações

Exemplo 1: Gerar dados de duas populações N_2

Exemplo 2: Analisar os dados de duas espécies de Moscas (Johnson and Wichern, 1992)