

MAE 5776

ANÁLISE MULTIVARIADA

Júlia M Pavan Soler
pavan@ime.usp.br

1º Semestre/2022

Já vimos 😊

MAE5776

$$Y_{n \times p} = (Y_{ij}) \in \mathbb{R}^{n \times p}$$

- Estatísticas descritivas multivariadas: \mathbb{R}^p , $\mathbb{R}^{p \times p}$, $\mathbb{R}^{n \times n}$
- Inferência sobre $\mu \in \mathbb{R}^p$:

Caso de Uma Única População

O problema de
Comparações Múltiplas

Caso de Duas Populações: Amostras pareadas e Amostras Independentes

⇒ **Caso de Duas ou Mais Populações (MANOVA):**

- ✓ Delineamento Completamente Aleatorizado (DCA) com Um Fator em G níveis

$$\left\{ \begin{array}{l} \text{Entre} \quad \text{Dentro} \\ SST = SSB + SSW \\ (T = H + E) \Rightarrow |H - \lambda E| = 0 \end{array} \right.$$

Teste de $H_0: \mu_g = \mu$ sob Observações Independentes, N_p e Homocedasticidade: Há diferentes estatísticas de teste (lambda de Wilks, Pillai, Roy).



- DCA Fatorial
- DCA Hierárquico
- Delineamento Aleatorizado em Blocos

MANOVA: Delineamento Completamente Aleatorizado com Um Único Fator

	T6	T12	T18	Trat
1	1.48	2.81	3.56	1
2	1.04	2.07	2.81	2
3	1.48	2.52	3.41	1
4	1.04	1.93	2.89	2
5	1.80	2.15	3.20	1
6	1.50	2.70	3.75	2
...				
23	1.80	2.15	3.90	1
24	1.20	2.25	3.30	2
25	1.78	2.96	4.00	3
26	1.48	2.81	3.85	4
27	1.33	2.52	3.84	3
28	1.03	2.07	2.96	4
29	1.65	3.00	3.98	3
30	1.50	2.85	3.75	4
...				
45	1.65	3.00	4.05	3
46	1.20	2.70	3.90	4
47	1.35	2.55	3.67	3
48	1.20	2.70	3.60	4

Considere os seguintes dados de um **Delineamento Completamente Aleatorizado com 1 Fator Tratamento em 4 níveis** (Trat=1, Trat=2, Trat=3 e Trat=4)

$p=3$ **variáveis** (medidas repetidas de O2): T6, T12 e T18

$$Y_{48 \times (3+1)}$$

3 variáveis resposta quantitativas e 1 categórica (identificando grupo)

MANOVA.RM do R

Centróides

	T6	T12	T18
Total (n=48)	1.497500	2.558333	3.664375

Trat	T6	T12	T18
1 (n=9)	1.618333	2.434167	3.526667
2 (n=9)	1.321667	2.430000	3.425000
3 (n=9)	1.655833	2.799167	4.029167
4 (n=9)	1.394167	2.570000	3.676667

Matrizes de Covariância

	T6	T12	T18	Trat
1	1.48	2.81	3.56	1
2	1.04	2.07	2.81	2
3	1.48	2.52	3.41	1
4	1.04	1.93	2.89	2
5	1.80	2.15	3.20	1
6	1.50	2.70	3.75	2
...				
23	1.80	2.15	3.90	1
24	1.20	2.25	3.30	2
25	1.78	2.96	4.00	3
26	1.48	2.81	3.85	4
27	1.33	2.52	3.84	3
28	1.03	2.07	2.96	4
29	1.65	3.00	3.98	3
30	1.50	2.85	3.75	4
...				
45	1.65	3.00	4.05	3
46	1.20	2.70	3.90	4
47	1.35	2.55	3.67	3
48	1.20	2.70	3.60	4

```

Trat=1      T6      T12      T18
T6          0.02   -0.02   0.00
T12        -0.02    0.09   0.00
T18         0.00    0.00   0.08

```

```

Trat=2      T6      T12      T18
T6          0.04    0.04   0.04
T12         0.04    0.07   0.06
T18         0.04    0.06   0.11

```

```

Trat=3      T6      T12      T18
T6          0.04    0.01   0.05
T12         0.01    0.11   0.01
T18         0.05    0.01   0.07

```

```

Trat=4      T6      T12      T18
T6          0.05    0.02   0.06
T12         0.02    0.06   0.05
T18         0.06    0.05   0.12

```

```

Sc          T6      T12      T18
T6          0.04    0.01   0.03
T12         0.01    0.08   0.03
T18         0.03    0.03   0.09

```

Box's M-test:

Chi-Sq=34.61, df = 18,
p-value = 0.01058

$\alpha=1\% \Rightarrow$ Não há
evidência para a
rejeição da hipótese
de Homocedasticidade

Atenção à decomposição
imposta à Matriz de Covariância

$$SST = SSB + SSW$$

Tabela de MANOVA:

FV	no.gl	SQPC			
Trat	4-1	SSB	T6	T12	T18
		T6	0.98	0.53	0.98
		T12	0.53	1.08	1.63
		T18	0.98	1.63	2.51
Resíduo	48-4	SSW	T6	T12	T18
		T6	1.67	0.55	1.53
		T12	0.55	3.66	1.24
		T18	1.53	1.24	4.15
Total	48-1	SST	T6	T12	T18
		T6	2.65	1.08	2.51
		T12	1.08	4.74	2.87
		T18	2.51	2.87	6.67

Fonte de
Variação
ENTRE
grupos

Fonte de
Variação
DENTRO
de grupos

	T6	T12	T18	Trat
1	1.48	2.81	3.56	1
2	1.04	2.07	2.81	2
3	1.48	2.52	3.41	1
4	1.04	1.93	2.89	2
5	1.80	2.15	3.20	1
6	1.50	2.70	3.75	2
...				
23	1.80	2.15	3.90	1
24	1.20	2.25	3.30	2
25	1.78	2.96	4.00	3
26	1.48	2.81	3.85	4
27	1.33	2.52	3.84	3
28	1.03	2.07	2.96	4
29	1.65	3.00	3.98	3
30	1.50	2.85	3.75	4
...				
45	1.65	3.00	4.05	3
46	1.20	2.70	3.90	4
47	1.35	2.55	3.67	3
48	1.20	2.70	3.60	4

$$H_0: \mu_g = \mu_{3 \times 1}, \quad g = 1, \dots, 4$$

	Estat.	approxF	numDf	denDf	Pr(>F)	
Pillai	0.7651	5.0206	9	132	8.062e-06	***
Wilks	0.3807	5.5401	9	102.37	3.354e-06	***
Hotel.-Lawley	1.2444	5.6229	9	122	1.742e-06	***
Roy	0.7004	10.273	3	44	3.013e-05	***

Concl.?

Contribuição das variáveis para a discriminação dos Trats!

Decomposição Espectral de $E^{-1}H$:

Autovalores [,1] [,2] [,3]
 0.7004284 0.5425676 0.001408624

Atovetores
 [,1] [,2] [,3]
 T6 0.01632176 0.94481561 -0.08938875
 T12 -0.20483386 -0.07142574 -0.50725864
 T18 -0.40074216 -0.30089017 0.36425094

Modelo estrutural e distribucional adotado:

$$Y_{ig \ 3 \times 1} = \mu_g + e_{ig}; \quad e_{ig} \sim N_3(\mu_g; \Sigma)$$

$$= \mu + \tau_g + e_{ig}; \quad \sum_{g=1}^4 \tau_g = 0$$

Parametrização de desvios

$$= \begin{cases} \mu_1 + e_{i1} \\ \mu_1 + \tau_g + e_{ig}; \quad g = 2, 3, 4 \end{cases}$$

Parametrização casela de referência

Estimativas:

	T6	T12	T18
(Intercept)	1.6183333	2.434166667	3.5266667
Trat=2	-0.2966667	-0.004166667	-0.1016667
Trat=3	0.0375000	0.365000000	0.5025000
Trat=4	-0.2241667	0.135833333	0.1500000

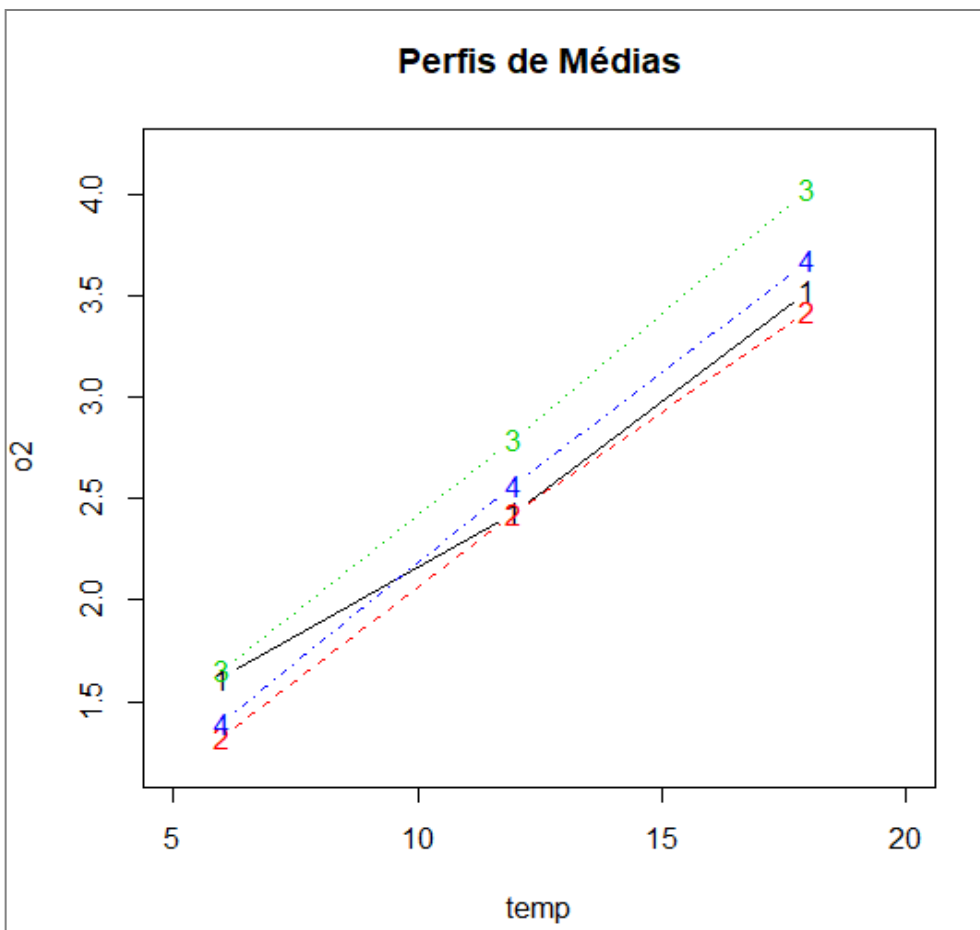
→ $\hat{\mu}_1$ Referência: Trat=1

→ $\hat{\tau}_g$; $g = 2, 3, 4$

Comparações Múltiplas

Intervalos de Confiança de Bonferroni (correção por variável)

Perfis de Médias



		Li	Ls	Conclusão
T6	[2-1]	-0.52	-0.08	$\mu_{21} < \mu_{11}$
	[3-1]	-0.18	0.26	$\mu_{31} = \mu_{11}$
	[4-1]	-0.44	0.00	$\mu_{41} = \mu_{11}$
	[3-2]	0.11	0.55	$\mu_{31} > \mu_{21}$
	[4-2]	-0.15	0.29	$\mu_{41} = \mu_{21}$
	[4-3]	-0.48	-0.04	$\mu_{41} < \mu_{31}$

*K=6
comparações*

T12	[2-1]	-0.33	0.32	$\mu_{22} = \mu_{12}$
	[3-1]	0.04	0.69	$\mu_{32} > \mu_{12}$
	[4-1]	-0.19	0.46	$\mu_{42} = \mu_{12}$
	[3-2]	0.04	0.69	$\mu_{32} > \mu_{22}$
	[4-2]	-0.19	0.47	$\mu_{42} = \mu_{22}$
	[4-3]	-0.55	0.10	$\mu_{42} = \mu_{32}$

K=6

T18	[2-1]	-0.45	0.24	$\mu_{23} = \mu_{13}$
	[3-1]	0.16	0.85	$\mu_{33} > \mu_{13}$
	[4-1]	-0.20	0.50	$\mu_{43} = \mu_{13}$
	[3-2]	0.26	0.95	$\mu_{33} > \mu_{23}$
	[4-2]	-0.09	0.60	$\mu_{43} = \mu_{23}$
	[4-3]	-0.70	-0.01	$\mu_{43} < \mu_{33}$

K=6

$$ICB(\mu_{gj} - \mu_{hj}) \text{ a } (1-\alpha)100\% = (\bar{Y}_{gj} - \bar{Y}_{hj}) \pm t_{n-G}(\alpha/2K) \sqrt{V(\bar{Y}_{gj} - \bar{Y}_{hj})} \left(\frac{1}{n_g} + \frac{1}{n_h} \right) \frac{E_{jj}}{n-G}$$

MANOVA - Fontes de Variação

Dados simulados: Delineamento com População Estratificada em Muitos Grupos (G=15) e p=2

$$Y_{n \times p}; Y_{ig} \sim N_p(\mu_g; \Sigma)$$

⇒ Delineamento com um Fator (Grupo, Tratamento) em 15 níveis


$$SST = SSB + SSW$$

SSB: Fonte de Variabilidade Entre grupos (elipse maior)

SSW: Fonte de Variabilidade Dentro de grupos (elipses menores)
Em geral, sob homocedasticidade

Situação ideal:

- Efeito de Tratamento: $SSB > SSW$
- Poder da análise Multivariada: altas covariâncias e de sinais opostos nos componentes de variação SSB e SSW



MANOVA: Modelo Linear Multivariado

$$Y_{n \times p}; \quad n = n_1 + \dots + n_G$$

$$Y_{ig \, p \times 1} = \mu_g + e_{ig};$$

$$Y_{n \times p} = X_{n \times G} \beta_{G \times p} + e_{n \times p}$$

$$Y_{n \times p} = \begin{pmatrix} Y_{11} & Y_{12} & \dots & Y_{1p} \\ Y_{21} & Y_{22} & \dots & Y_{2p} \\ \dots & \dots & \dots & \dots \\ Y_{n1} & Y_{n2} & \dots & Y_{np} \end{pmatrix};$$

$$e_{n \times p} = \begin{pmatrix} e_{11} & e_{12} & \dots & e_{1p} \\ e_{21} & e_{22} & \dots & e_{2p} \\ \dots & \dots & \dots & \dots \\ e_{n1} & e_{n2} & \dots & e_{np} \end{pmatrix}.$$

Parametrização
de médias

$$X_{n \times G} = \begin{pmatrix} 1_{n_1} & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 1_{n_2} & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \vdots & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 1_{n_G} \end{pmatrix};$$

$$\beta_{G \times p} = \begin{pmatrix} \mu_{11} & \mu_{12} & \dots & \mu_{1p} \\ \mu_{21} & \mu_{22} & \dots & \mu_{2p} \\ \dots & \dots & \dots & \dots \\ \mu_{G1} & \mu_{G2} & \dots & \mu_{Gp} \end{pmatrix};$$

Parametrização
de desvios

$$X_{n \times G} = \begin{pmatrix} 1 & 1 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 1 & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 0 & 1 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & -1 & -1 & -1 \end{pmatrix};$$

$$\beta_{G \times p} = \begin{pmatrix} \mu_{\cdot 1} & \mu_{\cdot 2} & \dots & \mu_{\cdot p} \\ \tau_{11} & \tau_{12} & \dots & \tau_{1p} \\ \dots & \dots & \dots & \dots \\ \tau_{(G-1)1} & \tau_{(G-1)2} & \dots & \tau_{(G-1)p} \end{pmatrix};$$

MANOVA: Modelo Linear Multivariado

$$Y_{n \times p} = X_{n \times G} \beta_{G \times p} + e_{n \times p}$$

Estimadores de Mínimos Quadrados e de MVS

$$\hat{\beta} = (X'X)^{-1} X'Y \qquad \hat{Y} = X\hat{\beta} = X(X'X)^{-1} X'Y = PY$$

$$\hat{e} = Y - \hat{Y} = \left(I_n - X(X'X)^{-1} X' \right) Y = (I_n - P)Y \qquad \hat{e}'\hat{e} / n = \hat{\Sigma} = S$$

$$P = X(X'X)^{-1} X'$$

MANOVA: Modelo Linear Multivariado

$$Y_{n \times p} = X_{n \times G} \beta_{G \times p} + e_{n \times p}$$

Teste de Hipóteses Gerais

$$H_0 : C_{c \times G} \beta_{G \times p} U_{p \times u} = 0$$

$C_{c \times G}$: define contrastes entre as médias de grupos

$U_{p \times u}$: define contrastes entre as médias das variáveis

Estatísticas de Teste: Wilks, Pillai, Lawley-Hotelling, Roy

Lambda de Wilks : $\lambda = \frac{|E|}{|H + E|}$

Considerar os autovalores e autovetores de : $(H - \lambda E)l = 0$

$$H = (C\hat{\beta}U)' [C(X'X)^{-1}C']^{-1} C\hat{\beta}U \quad E = (YU)' [I - X(X'X)^{-1}X']^{-1} YU$$

MANOVA: Modelo Linear Multivariado

$$Y_{n \times p} = X_{n \times G} \beta_{G \times p} + e_{n \times p}$$

Teste de Hipóteses Gerais $H_0 : C_{c \times G} \beta_{G \times p} U_{p \times u} = 0$

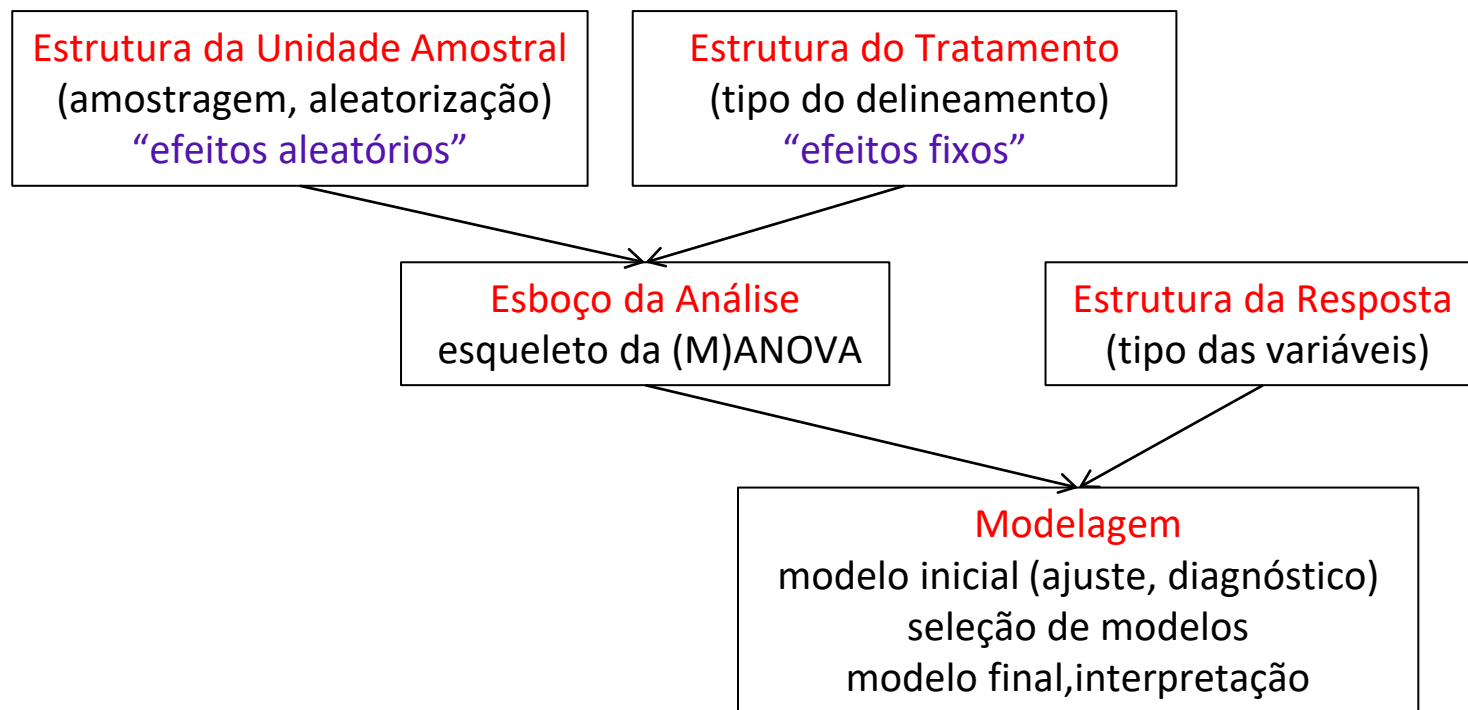
Exemplo: Considere um DCA balanceado e a parametrização de médias. Os seguintes **Contrastes Ortogonais** podem ser definidos (para comporem as linhas da matriz C): $C'_l C_{l_2} = 0$

$$\begin{array}{l} \text{G=3 Tratamentos} \left\{ \begin{array}{l} C1 = (1 \ 0 \ -1) \\ C2 = (\frac{1}{2} \ -1 \ \frac{1}{2}) \end{array} \right. \\ \\ \text{G=4 Tratamentos} \left\{ \begin{array}{l} C1 = (1 \ -1/3 \ -1/3 \ -1/3) \\ C2 = (0 \ -1/2 \ -1/2 \ 1) \\ C3 = (0 \ 1 \ -1 \ 0) \end{array} \right. \end{array}$$

Note que o número de graus de liberdade para estudar o efeito de Tratamento é (G-1): neste caso, a significância da estatística do teste coletivo das hipóteses é dada pela significância do correspondente efeito na tabela de MANOVA

Estrutura Geral de Análise de Dados

(Goos and Gilmour, 2012)



MANOVA – Diferentes Delineamentos

- **Estrutura da Resposta:** dados quantitativos multivariados ($\sim N_p$)
- **Estrutura das Unidades Amostras:** Observações independentes

Amostra aleatória simples de tamanho n de uma população sob estudo

Como os Tratamentos foram aleatorizados às unidades amostrais?

- ✓ Delineamento Completamente Aleatorizado (DCA)
Delineamento Aleatorizado em Blocos Completos (DABC)

- **Estrutura dos Tratamentos:**
 - ✓ Delineamento com Um Único Fator (em G níveis)
Delineamento Fatorial Cruzado (mais de um Fator)
Delineamento Fatorial Hierárquico

Delineamento Fatorial

Dados O2:

DCA com 1 Fator em 4 níveis →

DCA Fatorial 2x2: Dois Fatores, cada um em dois níveis

	T6	T12	T18	Trat
1	1.48	2.81	3.56	1
2	1.04	2.07	2.81	2
3	1.48	2.52	3.41	1
4	1.04	1.93	2.89	2
5	1.80	2.15	3.20	1
6	1.50	2.70	3.75	2
...				
23	1.80	2.15	3.90	1
24	1.20	2.25	3.30	2
25	1.78	2.96	4.00	3
26	1.48	2.81	3.85	4
27	1.33	2.52	3.84	3
28	1.03	2.07	2.96	4
29	1.65	3.00	3.98	3
30	1.50	2.85	3.75	4
...				
45	1.65	3.00	4.05	3
46	1.20	2.70	3.90	4
47	1.35	2.55	3.67	3
48	1.20	2.70	3.60	4

	Subj	Grup	Staph	T6	T12	T18
1	1	P	1	1.48	2.81	3.56
2	2	P	0	1.04	2.07	2.81
3	3	P	1	1.48	2.52	3.41
4	4	P	0	1.04	1.93	2.89
...						
21	21	P	1	1.50	2.85	3.12
22	22	P	0	1.65	2.70	3.40
23	23	P	1	1.80	2.15	3.90
24	24	P	0	1.20	2.25	3.30
25	25	V	1	1.78	2.96	4.00
26	26	V	0	1.48	2.81	3.85
27	27	V	1	1.33	2.52	3.84
28	28	V	0	1.03	2.07	2.96
...						
45	45	V	1	1.65	3.00	4.05
46	46	V	0	1.20	2.70	3.90
47	47	V	1	1.35	2.55	3.67
48	48	V	0	1.20	2.70	3.60

Estrutura de Dados

Dados: Medidas Repetidas no formato "wide"

Alternativa de
análise: MANOVA

```
> library(reshape2)
> dat.wide <- dcast(dat.long, Subj +
  Grup + Staph~ Time, value.var="O2")
> dat.wide
```

	Subj	Grup	Staph	6	12	18
1	1	P	1	1.48	2.81	3.56
2	2	P	0	1.04	2.07	2.81
3	3	P	1	1.48	2.52	3.41
4	4	P	0	1.04	1.93	2.89
...						
21	21	P	1	1.50	2.85	3.12
22	22	P	0	1.65	2.70	3.40
23	23	P	1	1.80	2.15	3.90
24	24	P	0	1.20	2.25	3.30
25	25	V	1	1.78	2.96	4.00
26	26	V	0	1.48	2.81	3.85
27	27	V	1	1.33	2.52	3.84
28	28	V	0	1.03	2.07	2.96
...						
45	45	V	1	1.65	3.00	4.05
46	46	V	0	1.20	2.70	3.90
47	47	V	1	1.35	2.55	3.67
48	48	V	0	1.20	2.70	3.60

Dados: Medidas Repetidas no formato "long"

Alternativa de
análise: Modelos
lineares mistos

```
> library(MANOVA.RM)
> dat.long<-o2cons
> dat.long
```

	O2	Staph	Time	Grup	Subj
1	1.48	1	6	P	1
2	2.81	1	12	P	1
3	3.56	1	18	P	1
4	1.04	0	6	P	2
5	2.07	0	12	P	2
6	2.81	0	18	P	2
...					
67	1.80	1	6	P	23
68	2.15	1	12	P	23
69	3.90	1	18	P	23
70	1.20	0	6	P	24
71	2.25	0	12	P	24
72	3.30	0	18	P	24
73	1.78	1	6	V	25
74	2.96	1	12	V	25
75	4.00	1	18	V	25
76	1.48	0	6	V	26
77	2.81	0	12	V	26
78	3.85	0	18	V	26
...					
139	1.35	1	6	V	47
140	2.55	1	12	V	47
141	3.67	1	18	V	47
142	1.20	0	6	V	48
143	2.70	0	12	V	48
144	3.60	0	18	V	48

Dados: Medidas Repetidas no formato "wide"

```
> library(reshape2)
> dat.wide <- dcast(dat.long, Subj +
  Grup + Staph~ Time, value.var="O2")
> dat.wide
```

	Subj	Grup	Staph	6	12	18
1	1	P	1	1.48	2.81	3.56
2	2	P	0	1.04	2.07	2.81
3	3	P	1	1.48	2.52	3.41
4	4	P	0	1.04	1.93	2.89
...						
21	21	P	1	1.50	2.85	3.12
22	22	P	0	1.65	2.70	3.40
23	23	P	1	1.80	2.15	3.90
24	24	P	0	1.20	2.25	3.30
25	25	V	1	1.78	2.96	4.00
26	26	V	0	1.48	2.81	3.85
27	27	V	1	1.33	2.52	3.84
28	28	V	0	1.03	2.07	2.96
...						
45	45	V	1	1.65	3.00	4.05
46	46	V	0	1.20	2.70	3.90
47	47	V	1	1.35	2.55	3.67
48	48	V	0	1.20	2.70	3.60

Delineamento Fatorial 2x2,

ou

✓ Um Fator em 4 níveis

Entendendo a estrutura dos dados:

Delineamento Completamente Aleatorizado,
Fatorial Cruzado:

Fator Grupo (2 níveis): P e V

Fator Staphylococcus (2 níveis): 1 e 0

1 Fator em
4 níveis

Estrutura de aleatorização das unidades
amostrais (experimentais) aos fatores:
Delineamento Completamente Aleatorizado

Estrutura dos Fatores (Tratamentos):
Fatorial Cruzado
(4 Tratamentos no total: 2 fatores, cada um
em 2 níveis)

Delineamento balanceado: n=12 unidades
experimentais em cada Tratamento
(combinação dos fatores)

p=3 respostas avaliadas em cada sujeito
(medidas repetidas de O2)

Dados O2:

DCA Fatorial 2x2

```
> library(reshape2)
> dat.wide <- dcast(dat.long, Subj +
  Grup + Staph~ Time, value.var="O2")
> dat.wide
```

	Subj	Grup	Staph	6	12	18
1	1	P	1	1.48	2.81	3.56
2	2	P	0	1.04	2.07	2.81
3	3	P	1	1.48	2.52	3.41
4	4	P	0	1.04	1.93	2.89
...						
21	21	P	1	1.50	2.85	3.12
22	22	P	0	1.65	2.70	3.40
23	23	P	1	1.80	2.15	3.90
24	24	P	0	1.20	2.25	3.30
25	25	V	1	1.78	2.96	4.00
26	26	V	0	1.48	2.81	3.85
27	27	V	1	1.33	2.52	3.84
28	28	V	0	1.03	2.07	2.96
...						
45	45	V	1	1.65	3.00	4.05
46	46	V	0	1.20	2.70	3.90
47	47	V	1	1.35	2.55	3.67
48	48	V	0	1.20	2.70	3.60

Centróides

	T6	T12	T18
Total	1.497500	2.558333	3.664375

Grup	T6	T12	T18
P	1.470	2.432083	3.475833
V	1.525	2.684583	3.852917

Staph	T6	T12	T18
0	1.357917	2.500000	3.550833
1	1.637083	2.616667	3.777917

G*S	T6	T12	T18
1	1.618333	2.434167	3.526667
2	1.321667	2.430000	3.425000
3	1.655833	2.799167	4.029167
4	1.394167	2.570000	3.676667

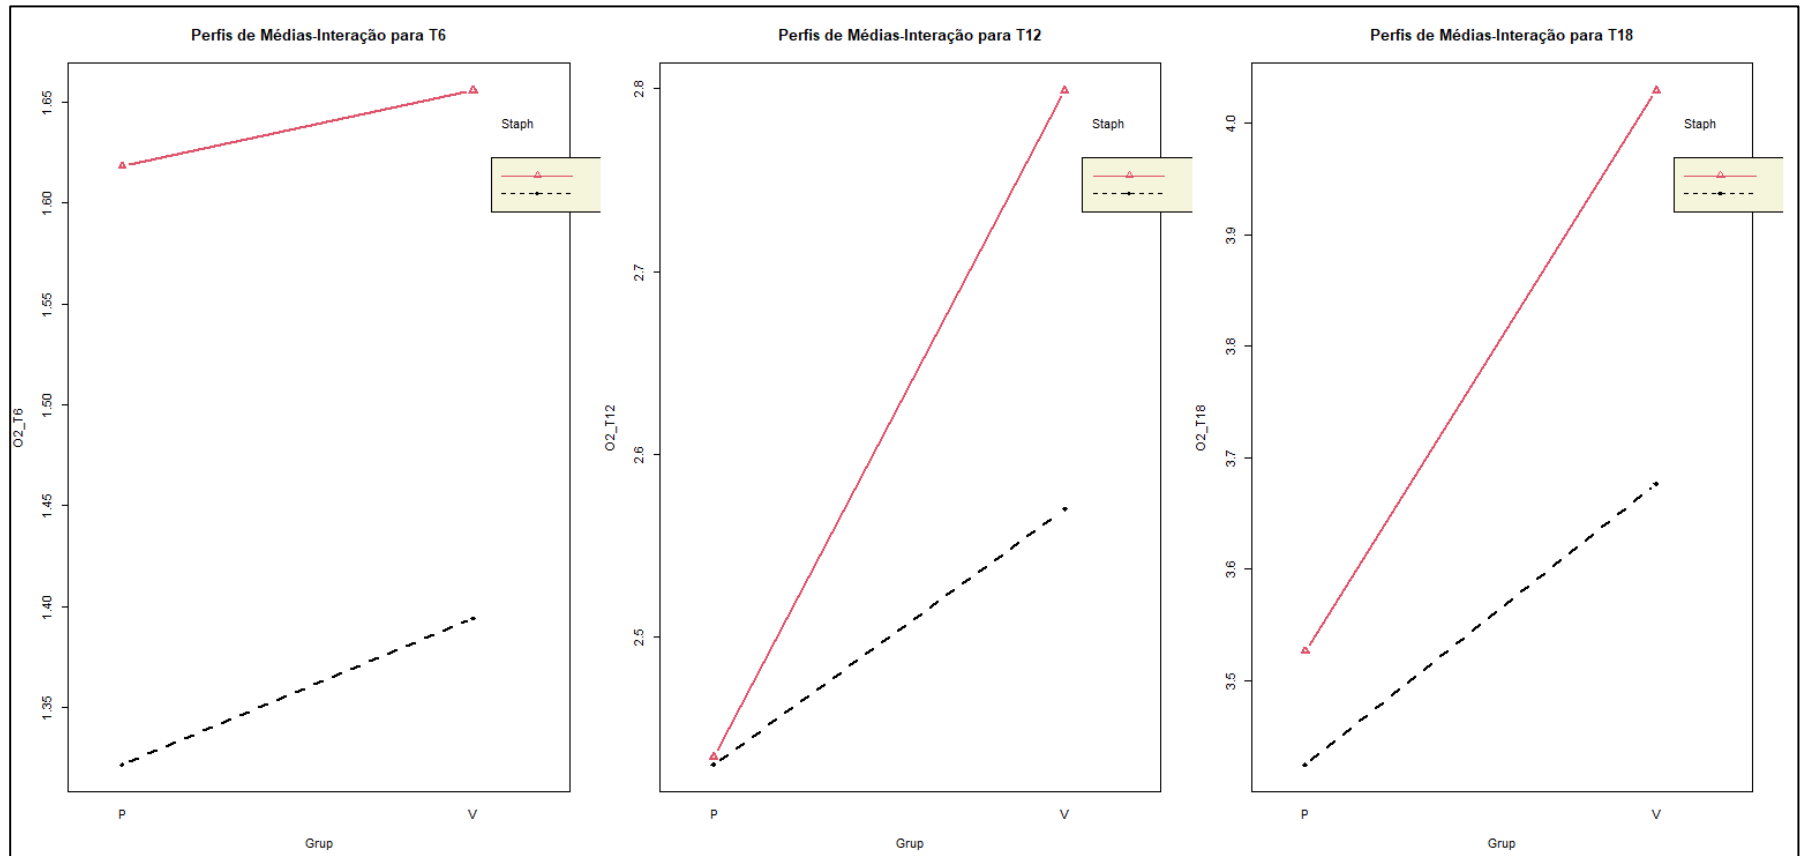
- Ajuste de modelos MANOVA sob
Delineamento Fatorial Cruzado!

Delineamento Fatorial

Efeito de Interação entre Fatores

Dados O2:

DCA Fatorial 2x2



Delineamento Fatorial

Um estudo tem como objetivo avaliar as condições de fabricação de um filme plástico. Três variáveis resposta (Y1, Y2 e Y3) foram observadas sob dois níveis (baixo e alto) dos fatores F1 e F2.

Dados do Arquivo EXH

		Maq2 F2					
		Baixo			Alto		
Maq1	F1	Y1	Y2	Y3	Y1	Y2	Y3
Baixo		6,5	9,5	4,4	6,9	9,1	5,7
		6,2	9,9	6,4	7,2	10	2
		5,8	9,6	3	6,9	9,9	3,9
		6,5	9,6	4,1	6,1	9,5	1,9
		6,5	9,2	0,8	6,3	9,4	5,7
Alto		6,7	9,1	2,8	7,1	9,2	8,4
		6,6	9,3	4,1	7	8,8	5,2
		7,2	8,3	3,8	7,2	9,7	6,9
		7,1	8,4	1,6	7,5	10,1	2,7
		6,8	8,5	3,4	7,6	9,2	1,9

*DCA Fatorial
Cruzado (2x2)
Balanceado
(n=20)*

$Y_{20 \times (3+1)}$

p=3 variáveis
e a categoria
de grupo.

⇒ Realizar uma análise de Variância Multivariada destes dados.

Delineamento Fatorial - ANOVA


Ef. principal de F1
Ef. principal de F2
Ef. de interação
Resíduo

$$y_{ijk} = \mu_{jk} + e_{ijk} = \mu + \tau_j + \beta_k + \gamma_{jk} + e_{ijk}$$

↓
Resposta da observação i avaliada no
nível j do fator 1 e nível k do fator 2

Restrições de identificabilidade

$$\sum_{j=1}^a \tau_j = 0, \sum_{k=1}^b \beta_k = 0, \sum_{j=1}^a \gamma_{jk} = 0, \sum_{k=1}^b \gamma_{jk} = 0$$



“Identidade útil” para obtenção das Somas de Quadrados e dos estimadores dos efeitos de interesse:

$$y_{ijk} = \bar{y} + (\bar{y}_{.j} - \bar{y}) + (\bar{y}_{.k} - \bar{y}) + (\bar{y}_{jk} - \bar{y}_{.j} - \bar{y}_{.k} + \bar{y}) + (y_{ijk} - \bar{y}_{jk})$$

SQ_F1
SQ_F2
SQ_F1*F2
SQ_Residual

Caso Multivariado \Rightarrow formulação para o vetor de resposta p-dimensional.

Tabela de MANOVA

Delineamento
Completamente
Aleatorizado com
estrutura Fatorial de
Grupos ($G=AXB$) e r
réplicas (balanceado)

F.V.	g.l.	Matriz de SSCP
Fator 1	a-1	$HF1 = \sum_{j=1}^a br \left(\bar{Y}_{j.} - \bar{Y} \right) \left(\bar{Y}_{j.} - \bar{Y} \right)'$
Fator 2	b-1	$HF2 = \sum_{k=1}^b ar \left(\bar{Y}_{.k} - \bar{Y} \right) \left(\bar{Y}_{.k} - \bar{Y} \right)'$
Interação	(a-1)(b-1)	$HInt = \sum_{j=1}^a \sum_{k=1}^b r \left(\bar{Y}_{jk} - \bar{Y}_{j.} - \bar{Y}_{.k} + \bar{Y} \right) \left(\bar{Y}_{jk} - \bar{Y}_{j.} - \bar{Y}_{.k} + \bar{Y} \right)'$
Resíduo	ab(r-1)	$E = \sum_{j=1}^a \sum_{k=1}^b \sum_{i=1}^r \left(Y_{ijk} - \bar{Y}_{jk} \right) \left(Y_{ijk} - \bar{Y}_{jk} \right)'$
TOTAL	rab-1	$HF1 + HF2 + HInt + E = \sum_{j=1}^a \sum_{k=1}^b \sum_{i=1}^r \left(Y_{ijk} - \bar{Y} \right) \left(Y_{ijk} - \bar{Y} \right)'$

Tabela de MANOVA

F.V.	Estatística Multivariada	Distribuição (Bartlett)
Interação	$\Lambda_{Int}^* = \frac{ E }{ HInt + E }$	$-\left(ab(r-1) - \frac{p+1-(a-1)(b-1)}{2}\right) \ln \Lambda_{Int}^* \sim \chi^2_{(a-1)(b-1)p}$
Fator 1	$\Lambda_{F1}^* = \frac{ E }{ HF1 + E }$	$-\left(ab(r-1) - \frac{p+1-(a-1)}{2}\right) \ln \Lambda_{F1}^* \sim \chi^2_{(a-1)p}$
Fator 2	$\Lambda_{F2}^* = \frac{ E }{ HF2 + E }$	$-\left(ab(r-1) - \frac{p+1-(b-1)}{2}\right) \ln \Lambda_{F2}^* \sim \chi^2_{(b-1)p}$

Testar a interação com os efeitos principais no modelo!

Testar os efeitos principais somente sob *inexistência de interação* (modelo aditivo)!

Delineamento Fatorial

Dados O2:

DCA Fatorial 2x2

	Df	Pillai	approx F	num Df	den Df	Pr(>F)	
Grup	1	0.36121	7.9165	3	42	0.0002686	***
Staph	1	0.36152	7.9270	3	42	0.0002660	***
Grup:Staph	1	0.10131	1.5782	3	42	0.2088765	
Residuals	44						

Conclusão: Não há evidência para efeito de interação significativa

Modelo Reduzido (sem a interação)

	Df	Pillai	approx F	num Df	den Df	Pr(>F)	
Grup	1	0.33988	7.3798	3	43	0.0004280	***
Staph	1	0.36086	8.0927	3	43	0.0002194	***
Residuals	45						

Grup	X6	X12	X18
1 P	1.470	2.432083	3.475833
2 V	1.525	2.684583	3.852917

Staph	X6	X12	X18
1	0	1.357917	2.500000
2	1	1.637083	2.616667

Realize comparações múltiplas para estudar os efeitos principais dos fatores

Delineamento Aleatorizado em Blocos Completos

Considere os dados de fabricação de um filme plástico: três variáveis (Y1, Y2 e Y3) foram observadas sob dois níveis (baixo e alto) de regulação das Máquinas Maq1 e Maq2. Os materiais de filme plástico estão bloqueados de acordo com o fornecedor.

Maq1		Baixo						Alto					
Maq2		Baixo			Alto			Baixo			Alto		
Bloco		Y1	Y2	Y3	Y1	Y2	Y3	Y1	Y2	Y3	Y1	Y2	Y3
1		6,5	9,5	4,4	6,9	9,1	5,7	6,7	9,1	2,8	7,1	9,2	8,4
2		6,2	9,9	6,4	7,2	10	2	6,6	9,3	4,1	7	8,8	5,2
3		5,8	9,6	3	6,9	9,9	3,9	7,2	8,3	3,8	7,2	9,7	6,9
4		6,5	9,6	4,1	6,1	9,5	1,9	7,1	8,4	1,6	7,5	10,1	2,7
5		6,5	9,2	0,8	6,3	9,4	5,7	6,8	8,5	3,4	7,6	9,2	1,9

Estrutura dos tratamentos:
Fatorial 2x2

Estrutura de aleatorização das unidades amostrais aos tratamentos é restrita a **Blocos**.

⇒ Considere que as unidades amostrais (total de 20) estão

Blocadas, de tal forma que há 5 blocos de 4 observações (homogêneas).

Dentro de cada bloco os 4 tratamentos foram aleatorizados às observações.

Note que **NÃO** há réplicas dentro dos níveis do fator Bloco.

Delineamento Aleatorizado em Blocos Completos - ANOVA


$$y_{gk} = \mu + \tau_g + \beta_k + e_{gk}$$

Ef. principal de Trat Ef. de Bloco

↓
Resposta da observação avaliada no nível g do Fator de interesse e no nível k do Fator Bloco (não há réplica)

Restrições de identificabilidade dos parâmetros

$$\sum_{g=1}^G \tau_g = 0, \sum_{k=1}^b \beta_k = 0$$



“Identidade útil” para obtenção das Somas de Quadrados e dos estimadores dos efeitos de interesse:

$$y_{gk} = \bar{y} + (\bar{y}_{g.} - \bar{y}) + (\bar{y}_{.k} - \bar{y}) + (y_{gk} - \bar{y}_{g.} - \bar{y}_{.k} + \bar{y})$$

Ef. principal do Fator de interesse Efeito do fator Bloco Resíduo: é o ef. de interação entre o fator de interesse e Bloco

SQ_F1 SQ_F2 SQ_Residual

Caso Multivariado \Rightarrow formulação para o vetor de resposta p-dimensional.

Tabela de MANOVA

Delineamento Aleatorizado em Blocos Completos

F.V.	g.l.	Matriz de SSCP
Fator	G-1	$HF1 = \sum_{g=1}^G b \left(\bar{Y}_{g\cdot} - \bar{Y} \right) \left(\bar{Y}_{g\cdot} - \bar{Y} \right)'$
Bloco	b-1	$HF2 = \sum_{k=1}^b G \left(\bar{Y}_{\cdot k} - \bar{Y} \right) \left(\bar{Y}_{\cdot k} - \bar{Y} \right)'$
Resíduo	(G-1)(b-1)	$E = \sum_{g=1}^G \sum_{k=1}^b \left(Y_{gk} - \bar{Y}_{g\cdot} - \bar{Y}_{\cdot k} + \bar{Y} \right) \left(Y_{gk} - \bar{Y}_{g\cdot} - \bar{Y}_{\cdot k} + \bar{Y} \right)'$
TOTAL	Gb-1	$HF1 + HF2 + E = \sum_{g=1}^G \sum_{k=1}^b \left(Y_{gk} - \bar{Y} \right) \left(Y_{gk} - \bar{Y} \right)'$

Delineamento Hierárquico (*Nested*)

Considere o seguinte experimento em que as notas dos alunos foram avaliadas segundo Escola e Método de Ensino (A, B, C e D)

Escola 1				Escola 2			
Método A		Método B		Método C		Método D	
Nota1	Nota2	Nota1	Nota2	Nota1	Nota2	Nota1	Nota2
7.6	8.2	9.2	9.2	5.6	10.0	6.2	8.8
5.9	7.7	4.3	4.3	7.7	6.9	4.9	4.8
...
4.8	6.5	9.0	9.0	5.8	7.8	8.8	7.3

Estrutura hierárquica dos fatores

$p=2$

DCA: atribuição aleatória dos estudantes às salas de aula

Estrutura de Tratamentos: há dois fatores hierárquicos Método(Escola).

O fator Método de Ensino está definido DENTRO do fator Escola.

Delineamento Hierárquico (*Nested*) - ANOVA

Efeitos Fixos dos Fatores


$$y_{ijk} = \mu + \tau_j + \beta_{k(j)} + e_{ijk}$$

Ef. principal de F1
Ef. de F2(F1)

↓
Resposta da observação i avaliada no nível
k do Fator 2 dentro do nível j do Fator 1

Restrições de identificabilidade dos parâmetros

$$\sum_{j=1}^a \tau_j = 0, \sum_{k=1}^b \beta_{k(j)} = 0$$



“Identidade útil” para obtenção das Somas de Quadrados e dos estimadores dos efeitos de interesse:

$$y_{ijk} = \bar{y} + (\bar{y}_{j.} - \bar{y}) + (\bar{y}_{jk} - \bar{y}_{j.}) + (y_{ijk} - \bar{y}_{jk})$$

Ef. principal de F1
Ef. de F2 dentro de F1: é a soma do ef. de F2 e da interação

Resíduo

SQ_F1 SQ_F2(F1) SQ_Residual

Caso Multivariado \Rightarrow descrever os resultados para o vetor de resposta p-dimensional.

Tabela de MANOVA

Delineamento Hierárquico (“Nested”)

Fonte de Variação	Número de g.l.	Matriz de SQPC
F1	a-1	$H_{F1_{p \times p}} = \sum_{j=1}^a a \left(\bar{Y}_j - \bar{Y} \right) \left(\bar{Y}_j - \bar{Y} \right)'$
F2(F1)	a(b-1)	$H_{F2(F1)_{p \times p}} = \sum_{j=1}^4 \sum_{k=1}^4 r \left(\bar{Y}_{jk} - \bar{Y}_j \right) \left(\bar{Y}_{jk} - \bar{Y}_j \right)'$
Resíduo	ab(r-1)	$E_{p \times p} = \sum_{j=1}^a \sum_{k=1}^b \sum_{i=1}^r \left(Y_{ijk} - \bar{Y}_{jk} \right) \left(Y_{ijk} - \bar{Y}_{jk} \right)'$
Total	abr-1	$\sum_{j=1}^a \sum_{k=1}^b \sum_{i=1}^r \left(Y_{ijk} - \bar{Y} \right) \left(Y_{ijk} - \bar{Y} \right)'$

Modelos MANOVA

Pense nas possíveis decomposições da matriz de observações $Y_{n \times p}$

Decomposições (Identities) úteis para a construção das SQPC

Modelo de um único fator: $y_{ig} = \bar{y} + (\bar{y}_g - \bar{y}) + (y_{ig} - \bar{y}_g)$ **T=H+E**

DCA

Fatorial Cruzado: $y_{ijk} = \bar{y} + (\bar{y}_{j.} - \bar{y}) + (\bar{y}_{.k} - \bar{y}) + (\bar{y}_{jk} - \bar{y}_{j.} - \bar{y}_{.k} + \bar{y}) + (y_{ijk} - \bar{y}_{jk})$

T=H1+H2+H1*H2+E

O efeito de F2 dentro de F1 é a soma do efeito principal de F1 e do efeito de interação

Fatorial Hierárquico: $y_{ijk} = \bar{y} + (\bar{y}_{j.} - \bar{y}) + (\bar{y}_{jk} - \bar{y}_{j.}) + (y_{ijk} - \bar{y}_{jk})$ **T=H1+H2(H1)+E**

O ef. de interação entre Bloco (F2) e F1 é o resíduo (**modelo aditivo**)

DABC

Modelo com fator Bloco: $y_{jk} = \bar{y} + (\bar{y}_{j.} - \bar{y}) + (\bar{y}_{.k} - \bar{y}) + (y_{jk} - \bar{y}_{j.} - \bar{y}_{.k} + \bar{y})$

T=H1+Bloco+E

Modelos MANOVA

Decomposição da Matriz $Y_{n \times p}$

**ASCA: ANOVA-Simultaneous
Component Analysis**
(Smilde et al., 2005)

Modelo de um único fator: (p=1) $y_{ig} = \bar{y} + (\bar{y}_g - \bar{y}) + (y_{ig} - \bar{y}_g)$



Para p>1: $Y_{ig \text{ } p \times 1} = \bar{Y}_{p \times 1} + (\bar{Y}_g - \bar{Y})_{p \times 1} + (Y_{ig} - \bar{Y}_g)_{p \times 1}$



$$Y_{n \times p}; n = \sum_{g=1}^G n_g$$

Decomposição de Y devido
à estrutura de grupos.

$$Y_{n \times p} = M_{n \times p} + T_{n \times p} + E_{n \times p}$$

Matriz de
Médias

Componente da
variabilidade
ENTRE grupos

Componente da
variabilidade
DENTRO de grupos

Exemplo

Duas variáveis avaliadas em unidades amostrais submetidas a 3 tratamentos

T1		T2		T3	
Y11	Y12	Y21	Y22	Y31	Y32
9	3	0	4	3	8
6	2	2	0	1	9
9	7			2	7
8	4	1	2	2	8
Média geral = (4 , 5)					


$$\begin{matrix} Y_{8 \times 2} \\ \begin{pmatrix} 9 & 3 \\ 6 & 2 \\ 9 & 7 \\ 0 & 4 \\ 2 & 0 \\ 3 & 8 \\ 1 & 9 \\ 2 & 7 \end{pmatrix} \end{matrix} = \begin{matrix} M_{8 \times 2} \\ \begin{pmatrix} 4 & 5 \\ 4 & 5 \\ 4 & 5 \\ 4 & 5 \\ 4 & 5 \\ 4 & 5 \\ 4 & 5 \\ 4 & 5 \end{pmatrix} \end{matrix} + \begin{matrix} T_{8 \times 2} \\ \begin{pmatrix} 4 & 3 \\ 4 & 2 \\ 4 & 7 \\ -3 & 4 \\ -3 & 0 \\ -2 & 3 \\ -2 & 3 \\ -2 & 3 \end{pmatrix} \end{matrix} + \begin{matrix} E_{8 \times 2} \\ \begin{pmatrix} 1 & -1 \\ -2 & -2 \\ 1 & 3 \\ -1 & 2 \\ 1 & -2 \\ 1 & 0 \\ -1 & 1 \\ 0 & -1 \end{pmatrix} \end{matrix}$$

Dependendo do problema, pode haver interesse na análise multivariada, não de Y mas do componente **T** de Y, ou do componente **E** de Y (E: resíduo ou resposta Y normalizada)

Pense, por ex., no componente T definindo **Multicentros** do estudo. Pode haver interesse no efeito de Centros nos dados (usar T) ou mesmo em eliminar este efeito dos dados (usar E)!

P-Integração de Bancos de Dados

Dados de G Centros



$$Y_{n \times p}; \quad n = \sum_{g=1}^G n_g$$

$$Y_{n \times p} = M_{n \times p} + T_{n \times p} + E_{n \times p}$$

Realizar análises (redução de dimensionalidade) nos componentes da decomposição de Y

Ex.: Obter “componentes principais” de T (ou mesmo de E)

Ver mix-Omics_R